

M2 Actuariat

Matières :

PySpark

Analyse de données II

Machine Learning/Optimisation Stochastique

Enseignants : Anis Matoussi, Youssef Esstafa, Wajd Meskini, Samir Ben Hariz

Projet Data Science

Introduction

- **Contexte** : Un assureur veut créer un zonier tarifaire auto basé sur un score de sinistralité par commune.
- **Données** : Sinistres automobiles (data.gouv.fr) + données socio-économiques (INSEE).
- **Méthode** : Modèles prédictifs pour scorer les communes et construire des coefficients tarifaires.

Note : Les trois parties (PySpark, Analyse de données, Machine Learning) sont **notées séparément**. Le rapport doit refléter cette structure.

Parcours Data Science : La partie préparation des données doit être faite en PySpark (sur Colab).

Autres parcours : Utilisez Pandas pour obtenir un dataset équivalent.

Objectifs pédagogiques

- Se familiariser avec l'intégration de données depuis des sources diverses
- Créer des indicateurs utiles à partir de données brutes
- Comprendre les cas d'usage des différents modèles (régression, classification)
- Construire un **zonier tarifaire réel** avec coefficients par commune

Attention aux accidents de transit : Certaines communes ont une sinistralité élevée due au trafic de passage (autoroutes, zones touristiques), pas aux locaux. Identifiez ces cas et proposez un traitement approprié.

Définitions et hypothèses communes

Hypothèses du portefeuille fictif (à utiliser pour tous les calculs d'impact) :

- **Portefeuille** : 100 000 assurés répartis sur les communes selon leur population
- **Prime** : 100 € par tête
- **S/P** : 0.7
- **Coût moyen d'un accident** : 1 000 €

Format des clés communes :

- Les colonnes **com** et **dep** doivent être lues comme **chaînes de caractères**, pas comme entiers
- Si une jointure perd beaucoup de données, vérifiez le format de vos clés !

Data Leakage – Attention à éviter :

Le *data leakage* survient quand des informations du jeu de test "fuient" dans le jeu d'entraînement, faussant les métriques. Situations à risque :

- **Normalisation min-max** : Calculer min/max sur tout le dataset avant split
→ utiliser uniquement le train
- **ACP** : Ajuster l'ACP sur tout le dataset → ajuster sur train, appliquer sur test
- **Moyennes pour imputation** : Idem

Résultat final attendu : Appliquez votre zonier au portefeuille fictif et calculez l'impact sur les primes et le S/P. Présentez et justifiez vos résultats lors de la soutenance.

1 Partie manipulation et préparation des données

PySpark

1.1 Etape 1 : Lecture et jointure

1. Allez sur le site data.gouv.fr pour récupérer les données concernant les sinistres automobiles de 2023. Les données portent les noms de :
 - `caracteristiques_2023.csv`
 - `usagers_2023.csv`
 - `vehicules_2023.csv`
 - `lieux_2023.csv`
2. Récupérer au passage le descriptif des données : Les noms des colonnes étant difficiles à interpréter, il vous sera utile.
3. Lire les données sur votre programme. (Voir box "Format des clés" pour le format des colonnes com et dep)
4. Rassembler toutes les données dans un seul jeu de données. Identifiez quelles clés rassemblent quels fichiers. Attention à usagers et vehicules !
5. A la sortie après jointure, **une ligne = un accident**

1.2 Etape 2 : Extraction d'indicateurs

1. Essayez d'extraire des indicateurs pendant le regroupement par commune. Quelques exemples sont cités ci-dessous :
 - Proportion d'accidents entre 23h et 6h du matin par commune.
 - Proportion d'accidents sur des autoroutes.
 - Proportion d'accidents en hiver.
 - Proportion d'accidents en agglomération.
 - Proportion d'accidents en conditions atmosphériques anormales.
2. Séparer la colonne `grav` en 4 colonnes grâce au One-Hot Encoding (une colonne par modalité, 0 ou 1).

1.3 Etape 3 : Regroupement des données par commune

Regroupez les données par commune (voir box "Format des clés" ci-dessus). Pour l'agrégation :

- **Colonnes grav (one-hot)** : Somme (nombre d'accidents par type)
- **Indicateurs numériques** : Moyenne ou somme selon le sens
- **Indicateurs catégoriels** : Mode (valeur la plus fréquente)
- **Justifiez vos choix dans le rapport**
- A la fin de ce regroupement, **une ligne = une commune**

1.4 Etape 4 : Visualisation

Explorez votre jeu de données et essayez d'extraire des analyses utiles (dans le contexte assurantiel, économique ou social). Vous pourrez explorer l'effet de vos indicateurs sur les différentes variables issues de grav.

1.5 Etape 5 : Autres sources de données (INSEE)

Intégrez des données socio-économiques depuis l'INSEE. Sources suggérées :

- Population (P23_POP) : pour normaliser vos indicateurs
- Nombre de ménages (P23_MEN), superficie (SUPERF) → *base cc comparateur*
- Population par sexe/âge → *pop-sexe-age-quinquennal6816.xls*
- Salaire net horaire moyen → *base-cc-dads-2023.xlsx*
- Toute autre source pertinente que vous saurez justifier

1.6 Etape 6 : Préparation de la variable cible

1. Créer le score brut (par commune) :

$$\text{score} = 1 \times \text{indemnes} + 5 \times \text{blessés légers} + 25 \times \text{hospitalisés} + 100 \times \text{décès}$$

Justification : Les pondérations reflètent les ratios de coûts moyens observés dans l'industrie (dommages matériels ~2k€, blessures légères ~10k€, hospitalisations ~50k€, décès ~200k€).

Note : Vous pouvez proposer une formule alternative si vous la justifiez.

Objectif : Utiliser des modèles prédictifs à but explicatif, en modélisant la variable cible pour scorer les communes et construire le zonier tarifaire.

2. Normaliser le score :

- Appliquez un boxplot. Si valeurs extrêmes → transformation logarithmique
- Appliquez une normalisation min-max pour obtenir $\text{score_norm} \in [0, 1]$
- Rappel : Attention au data leakage (voir box ci-dessus)

3. Créer la variable binaire :

- score_bin : Vaut 1 si $\text{score} > \text{moyenne}$, 0 sinon
- Cette variable servira pour les modèles de classification et la construction du zonier

4. Train/Test split :

- Divisez le dataset en jeux train et test
- Expliquez pourquoi cette séparation est nécessaire

2 Modélisation avec méthodes factorielles et méthodes linéaires

Analyse de données II

2.1 Etape 7 : Régression et analyse factorielle

Note : Pour chaque modèle, reportez les métriques de performance vues en cours. Répétez chaque régression sur les axes principaux de l'ACP et comparez les résultats.

1. **Corrélations** : Extraire la matrice de corrélation. Expliquez pourquoi la multicolinéarité pose problème pour la régression linéaire.
2. **ACP** : Appliquez une ACP sur vos variables. Expliquez son utilité pour la réduction de dimensionnalité et la décorrélation. (Attention au data leakage!)
3. **Régression linéaire** : Prédire score_norm

4. Régression logistique : Prédire `score_bin`

3 Modélisation avec méthodes de Machine Learning avancées

Machine Learning et Optimisation Stochastique

3.1 Etape 8 : Modélisation

3.1.1 Partie Optimisation Stochastique

1. Appliquez une régression linéaire manuellement pour prédire la variable cible `score_norm`. L'optimisation de la fonction coût se fera par la descente du gradient classique.
2. Appliquez une régression linéaire manuellement pour prédire la variable cible `score_norm`. L'optimisation de la fonction coût se fera par la descente du gradient stochastique.
3. Appliquez une régression avec descente du gradient stochastique avec une librairie (classe `SGDClassifier` sur Python, fonction `sgd` sur R par exemple) pour prédire la variable cible `score_norm`. Comparez avec vos autres résultats et essayez d'expliquer la différence (ou son absence).

3.1.2 Partie Machine Learning

Appliquez **au moins 5 algorithmes** parmi les suivants pour prédire `score_bin` :

- KNN
- SVM (linéaire et/ou radial)
- Arbre de décision
- Random Forest / Bagging
- Gradient Boosting
- Régression logistique

Pour chaque modèle :

- Reportez les métriques de performance (accuracy, precision, recall, F1, AUC)
- Comparez les résultats
- Identifiez les cas d'usage de chaque modèle en ML

3.1.3 Partie Optimisation des Hyperparamètres

1. Tuning :

- Choisissez un modèle et optimisez ses hyperparamètres
- Méthodes : GridSearch, RandomSearch, ou boucle manuelle

2. Validation croisée :

- Validez la performance avec validation croisée (k-fold)
- Combinez avec la recherche d'hyperparamètres

3. Explicabilité :

- Utilisez SHAP ou eli5 pour l'importance des variables
- Expliquez pourquoi l'explicabilité est cruciale en assurance

4. Sélection de variables :

- Appliquez Recursive Feature Elimination (RFE)
- Observez l'impact sur la performance

4 Construction du Zonier Tarifaire

À cette étape, vous avez un modèle de classification. Nous allons le transformer en zonier tarifaire.

4.1 Pourquoi un modèle plutôt que les valeurs brutes ?

On pourrait directement utiliser `score_bin` observé pour construire le zonier. Cependant, l'approche par modélisation présente plusieurs avantages :

- **Lissage** : Les communes à faible population ont peu de sinistres ; les observations brutes sont peu fiables
- **Généralisation** : Le modèle peut prédire le risque de communes sans historique
- **Explicabilité** : Les coefficients identifient les facteurs de risque
- **Stabilité** : Les prédictions basées sur des caractéristiques stables sont moins volatiles année après année

4.2 Formule de construction du coefficient tarifaire

Utilisez `predict_proba` pour obtenir $P(\text{high_risk})$ par commune. Transformez en coefficient tarifaire :

$$\text{coefficient} = 1 + \alpha \times (P(\text{high_risk}) - 0.5)$$

Où α = variation maximale autorisée (ex : 0.2 pour $\pm 10\%$)

- $P = 0.5 \rightarrow \text{coefficient} = 1.0$ (pas de changement)
- $P = 1.0 \rightarrow \text{coefficient} = 1.1$ (+10%)
- $P = 0.0 \rightarrow \text{coefficient} = 0.9$ (-10%)

Prime par commune : $\text{prime_commune} = \text{prime_baseline} \times \text{coefficient}$

4.3 Exercice : Comparaison des zoniers

Construisez **deux zoniers** :

1. **Zonier naïf** : Coefficients basés directement sur `score_bin` observé
2. **Zonier modélisé** : Coefficients basés sur `predict_proba` de votre meilleur modèle

Comparez leur impact sur le portefeuille (voir hypothèses en début de document).

4.4 Impact sur le portefeuille

En utilisant les hypothèses du portefeuille fictif :

- Calculez l'impact de votre zonier sur la prime moyenne
- Calculez l'impact sur le S/P
- Testez **3 configurations** différentes (modèles/hyperparamètres) pour évaluer la sensibilité

5 Sitographie

Lien vers les données des sinistres corporels :

<https://www.data.gouv.fr/fr/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2022/>

Lien vers le descriptif :

<https://www.data.gouv.fr/fr/datasets/r/8ef4c2a3-91a0-4d98-ae3a-989bde87b62a>

base cc comparateur :

<https://www.insee.fr/fr/statistiques/2521169>

Populations :

<https://www.insee.fr/fr/statistiques/1893204>

Salaire net horaire moyen

